



Architecture Agent IA Beauté & Bien-être

Document de référence produit · Phase MVP → Production

Ce document décrit l'architecture complète de l'agent IA de **Jam** — plateforme de réservation beauté & bien-être pour le Cameroun et la zone CEMAC. Il couvre les trois phases de déploiement, la stack technique, les stratégies de prompt, les flux de données et la feuille de route.

L'agent IA est le **cœur différenciant** de Jam face aux acteurs internationaux (Fresha, Vagaro) : il parle **français, anglais et pidgin**, fonctionne en contexte de **faible connectivité** et répond aux spécificités du marché CEMAC.

Claude API (Anthropic)

Supabase

Next.js

Vercel

WhatsApp / SMS

Multilingue FR / EN / Pidgin

DIAGNOSTIC

Le problème que l'agent résout

Le marché de la beauté et du bien-être en Afrique centrale fonctionne encore largement à l'oral, par WhatsApp personnel et par recommandation. Cela crée trois frictions majeures.

**Disponibilité opaque**

Le client ne sait pas si le prestataire est libre avant d'appeler. Le prestataire gère son agenda à la main ou par mémoire.

**No-show fréquent**

Sans confirmation ni rappel automatique, le taux de rendez-vous manqués est structurellement élevé — perte directe de revenus.

**Faible fidélisation**

Aucun système ne suit l'historique client, ne rappelle la prochaine visite, ni ne propose des services additionnels.

L'agent IA comme réponse systémique

L'agent n'est pas un chatbot de support. C'est un **concierge intelligent bilatéral** qui opère simultanément côté client (expérience de réservation fluide) et côté prestataire (gestion active du business).

ARCHITECTURE EN 3 PHASES — VISION GLOBALE**PHASE 1 — MVP**

- Agent Client
- Booking en langage naturel
- Recommandation
- Rappels RDV
- FR / EN

Mois 1-3

**PHASE 2**

- + Agent Prestataire
- Mémoire client
- Planning optimizer
- Upsell automatique
- Insights business

Mois 4-6

**PHASE 3**

- Agent Bilatéral
- Agents interconnectés
- Pidgin camerounais
- WhatsApp natif
- Offline-first

Mois 7-12

Principe fondamental : mémoire persistante

Claude API est stateless par nature — chaque appel est indépendant. Le système Jam maintient la mémoire via **Supabase** (base de données relationnelle + vecteurs pgvector) et injecte le contexte pertinent dans chaque prompt système. C'est l'architecture context injection.


Contrainte CEMAC à anticiper : la connectivité mobile est instable dans les zones secondaires (Bafoussam, Bertoua, Garoua). L'agent doit être conçu pour des réponses courtes, une dégradation gracieuse en cas de timeout, et un fallback SMS/WhatsApp pour les rappels critiques.

MVP • Priorité 1

Agent Client — Booking & Recommandation

L'agent client est le premier point de contact. Il transforme une conversation en langage naturel en réservation confirmée — 24h/24, sans formulaire.

Flux principal



Capacités Phase 1

📌 Booking conversationnel

L'agent comprend des demandes comme "je veux un soin cheveux vendredi après 15h, budget 5000 FCFA, près de Akwa". Il reformule, confirme et réserve sans formulaire.

🎯 Recommandation personnalisée

L'agent utilise l'historique du client (services passés, prestataires notés, type de cheveux/peau renseigné) pour proposer les 2-3 meilleurs profils correspondants.

🔔 Rappels intelligents

Séquence automatique J-2, J-1, H-2 via push notification et WhatsApp. L'agent adapte le ton selon le profil (formel / informel). Réduit le no-show de 40-60% en moyenne.

🌐 Bilingue FR / EN

Détection automatique de la langue du message. Réponse dans la même langue. Préparation vocabulaire pidgin pour Phase 3.

Prompt Système — Phase 1


```
// System prompt injecté à chaque appel Claude API Tu es Jam, l'assistant de réservation beauté et bien-être au Cameroun. Ton rôle : aider le client à trouver et réserver le bon prestataire. // Contexte injecté dynamiquement depuis Supabase CLIENT : {prenom} · Dernière visite : {date_derniere_visite} Prestataires favoris : {liste_favoris} Services habituels : {historique_services} Localisation : {quartier_client} RÈGLES : - Réponds TOUJOURS dans la langue du message (FR ou EN) - Pose maximum UNE question de clarification à la fois - Si le créneau est libre → confirme et écris le RDV en JSON - Si aucun prestataire disponible → propose le créneau suivant - Ton : chaleureux, direct, jamais condescendant - Format confirmation : {"action":"book","prestataire_id":"...","slot":"..."}
```

Avantage technique : l'injection de contexte depuis Supabase (historique, favoris, géolocalisation) dans le prompt système permet à Claude de "se souvenir" du client sans stocker de mémoire côté LLM — architecture stateless, conforme RGPD et efficace sur la fenêtre de contexte.

Agent Prestataire — Business Intelligence & Rétention

L'agent prestataire transforme chaque professionnel en micro-entrepreneur outillé — carnet client digital, radar business et assistant commercial automatique.

Architecture côté prestataire



5 fonctionnalités clés

Fonctionnalité	Ce que fait l'agent	Impact business
Optimisation planning	Détecte les trous d'agenda, propose une offre flash aux clients réguliers correspondants	+15-25% de taux de remplissage agenda
Mémoire client	Fiche auto par client : type de cheveux/peau, allergies, historique, préférences, dernier service	Expérience personnalisée, fidélisation
Anti no-show	Séquence rappels adaptée (ton formel ou informel selon profil), confirmation 2-tap	-40 à -60% de no-shows
Upsell pré-visite	Suggère un service additionnel au client avant le RDV selon son historique et le service réservé	+20% panier moyen estimé
Rapport hebdo auto	Génère : CA semaine, taux no-show, top services, heures creuses, recommandations action	Décision data-driven sans comptable

Prompt Système — Agent Prestataire


```
Tu es l'assistant business de {prenom_prestataire}, professionnel·le de beauté sur Jam. CONTEXTE MÉTIER : Spécialité : {specialite} • Zone : {quartier} Agenda : {nb_creneaux_libres} créneaux libres cette semaine Taux no-show 30j : {taux_noshow}% • CA semaine : {ca_semaine} FCFA Clients actifs : {nb_clients} • Prochain RDV dans : {prochain_rdv} RÈGLES : - Ton : professionnel mais chaleureux, tu tutoies - Si créneaux vides > 3 → suggère une offre flash ciblée - Rapport hebdo → structure : highlights, alerte, recommandation - Réponse prospect → qualifie + propose créneau disponible - Ne divulgue JAMAIS les données d'un autre prestataire
```

Phase 3 • Mois 7-12

Agent Bilatéral — Interconnexion & Pidgin

Les deux agents se parlent via une couche événementielle Supabase Realtime. Un client posant une question sur les disponibilités obtient une réponse issue de l'agenda réel du prestataire — sans latence humaine.

Architecture bilatérale complète



Multilingue — stratégie pidgin

Le pidgin camerounais est la lingua franca de Douala et des marchés populaires. L'intégrer crée une barrière concurrentielle durable qu'aucune solution internationale ne peut répliquer facilement.

Approche technique : quelques dizaines d'exemples few-shot dans le prompt système suffisent à orienter Claude vers le registre pidgin. Pas besoin de fine-tuning. Tester avec des locuteurs natifs avant le lancement.

```
// Exemple few-shot pidgin dans le prompt User  
(pidgin): "I wan book hair for tomorrow wia i  
fit find good salon for Akwa?" Agent: "Na so! I  
don find 3 good salon for Akwa wey get space  
tomorrow. Wettin time you wan go — morning or  
afta lunch?" // → Claude maintient le registre  
pidgin
```

WhatsApp Business API — intégration native

En Phase 3, le canal WhatsApp devient natif (pas seulement des rappels). Le client peut réserver directement depuis WhatsApp sans ouvrir l'app. L'agent répond via webhook en moins de 3 secondes.



RÉFÉRENTIEL TECHNIQUE

Stack recommandée

La stack est calée sur ce qu'Elokan CS maîtrise déjà — réduction du risque technique, time-to-market optimal.

Composants par couche

FRONTEND / APP

Next.js 14+

App Router, Server Components. PWA pour mobile-first, mode offline via Service Worker.

DÉPLOIEMENT

Vercel

Edge Functions pour les webhooks temps-réel. CDN global — latence réduite depuis Douala.

BASE DE DONNÉES

Supabase

PostgreSQL (RLS par rôle), Realtime (WebSockets), pgvector pour embeddings mémoire client, Auth.

IA / AGENT

Claude API (Anthropic)

claude-sonnet-4 pour le raisonnement, claude-haiku-4 pour les tâches rapides (rappels, classification). Modèle : context injection + structured outputs JSON.

EMBEDDINGS MÉMOIRE

pgvector + Supabase

Embedding des historiques clients pour similarité sémantique (recommandation prestataire). Pas de service externe nécessaire.

MESSAGING

WhatsApp Business API

Rappels Phase 1–2. Canal natif Phase 3. Fallback SMS (Twilio ou opérateur local CAMTEL/MTN) pour zones hors data.

PROTOTYPAGE RAPIDE

Lovable

Génération UI initiale, composants. Exporter en Next.js pour production.

PM / DOCUMENTATION

Notion

Specs agent, prompts versionés, backlog, onboarding prestataires.

PAIEMENT (PHASE 2)

Mobile Money local

Orange Money CM + MTN MoMo. API CinetPay ou Campay pour l'intégration. Dépôt de garantie anti no-show.

Modèle de données Supabase (simplifié)

Table	Colonnes clés	Usage agent
clients	id, prenom, langue, quartier, type_cheveux, historique_services[]	Context injection prompt client
prestataires	id, specialites[], quartier, tarifs, note_moyenne, disponibilites	Matching + recommandation
reservations	id, client_id, presta_id, slot, statut, rappels_envoyes	Confirmation + anti no-show
conversations	id, client_id, messages JSONB, created_at	Historique session (non cross-session)
client_embeddings	client_id, embedding vector(1536), metadata	Recommandation sémantique (Phase 2)
analytics_presta	presta_id, semaine, ca, nb_noshow, top_services[]	Rapport hebdo agent prestataire

Row Level Security (RLS) — règle absolue : chaque prestataire ne peut lire que ses propres clients et réservations. Chaque client ne voit que ses propres données. L'agent appelle Supabase via un service role key côté serveur uniquement — jamais exposé au client.

NON-NÉGOCIABLE

Sécurité, confidentialité & adaptations locales

Gouvernance des données personnelles

CE QUE L'AGENT NE STOCKE PAS

Claude API est stateless : aucune conversation n'est stockée côté Anthropic au-delà de la session. Les seules données persistantes sont dans Supabase, sous contrôle d'Elokan CS.

Ne jamais stocker de données biométriques, photos ID, ou informations médicales dans les tables accessibles à l'agent.

CE QUE SUPABASE STOCKE

Historique de services (anonymisable), préférences déclarées, coordonnées de contact, historique des réservations. Durée de conservation : 24 mois actifs, puis archivage.

Prévoir une politique de suppression à la demande conforme à la loi camerounaise n°2010/012 sur la cybersécurité.

Adaptations CEMAC — connectivité dégradée

Risque	Mitigation technique
Timeout API (réseau lent)	Timeout Claude API à 15s. Fallback : réponse générique + re-tentative en background. Message user : "Jam prépare ta réponse..."
Client sans data (SMS only)	Fallback SMS pour rappels (Twilio / opérateur local). Booking simplifié par SMS structuré (Phase 3).
Coupures fréquentes	PWA avec Service Worker : cache des disponibilités localement, sync à la reconnexion via Supabase Realtime.
Païement sans carte bancaire	Mobile Money natif (Orange/MTN). L'agent peut initier une demande de paiement en fin de booking dès Phase 2.
Coût tokens IA en production	claude-haiku pour les tâches simples (rappels, classification), claude-sonnet pour le raisonnement complexe. Estim. coût : ~0.02 FCFA/interaction haiku.

Optimisation des coûts API Claude

STRATÉGIE DE ROUTAGE DES MODÈLES

claude-haiku-4 (rapide / économique)

- ✓ Classification intention
- ✓ Génération rappels SMS
- ✓ Réponses FAQ (horaires, tarifs)
- ✓ Détection langue
- ✓ Rapport hebdo simple

claude-sonnet-4 (raisonnement)

- ✓ Recommandation personnalisée
- ✓ Booking avec contraintes multiples
- ✓ Réponse prospect élaborée
- ✓ Insights business complexes
- ✓ Conversations multilingues

Monitoring & alertes

Supabase Edge Functions loggent chaque appel Claude (token count, latence, statut). Alertes Slack si : taux d'erreur API > 5%, latence moyenne > 10s, coût journalier > seuil défini. Dashboard opérationnel dans Notion/Supabase Studio.

PLANIFICATION

Feuille de route — 12 mois

Approche itérative : chaque phase valide des hypothèses avant d'investir dans la suivante. Le MVP (Phase 1) peut être opérationnel en 8 semaines avec la stack maîtrisée par Elokan CS.

- Sem 1-2** **Setup infrastructure** — Supabase (schéma + RLS + Auth), Next.js boilerplate, intégration Claude API, environnements dev/staging/prod sur Vercel. Prompt système v1.
- Sem 3-4** **MVP Agent Client v0** — Chat de booking fonctionnel (FR), context injection depuis Supabase, confirmation RDV, tests avec 5 prestataires pilotes Douala.
- Mois 2** **Rappels automatiques** — Cron Supabase Edge Functions J-2 / J-1 / H-2. Intégration WhatsApp Business API (Meta Developer). Métriques no-show baseline.
- Mois 3** **Phase 1 complète** — Recommandation personnalisée (historique client), bilingue FR/EN, onboarding 20-30 prestataires, dashboard basique client + prestataire.
- Mois 4-5** **Agent Prestataire (Phase 2)** — Mémoire client (pgvector embeddings), offres flash automatiques, upsell pré-visite, rapport hebdo généré. Test avec prestataires early adopters.
- Mois 6** **Mobile Money** — Intégration CinetPay/Campay (Orange Money + MTN MoMo). Dépôt de garantie anti no-show (500-1000 FCFA). Validation modèle de revenus commission.
- Mois 7-9** **Phase 3 — Bilatéral + Pidgin** — Agents interconnectés, WhatsApp comme canal natif, few-shot pidgin camerounais, PWA offline-first, extension villes (Yaoundé, Bafoussam).
- Mois 10-12** **Expansion CEMAC** — Localisation Gabon (Libreville), RCA (Bangui), Tchad (N'Djamena). Adaptation langues (lingala, sango). Partenariats opérateurs télécoms locaux pour SMS/data.

KPIs agent IA — Phase 1 (objectifs à 3 mois)

Taux de complétion booking % de conversations qui aboutissent à un RDV confirmé. Objectif : > 65%	Réduction no-show Baseline vs post-rappels agent. Objectif : -40% vs sans système	Satisfaction client (CSAT) Score post-interaction agent. Objectif : > 4.2 / 5 — dès M2
---	---	--

Prochaine étape concrète : créer le repo Next.js, initialiser le projet Supabase (schéma clients + prestataires + réservations), et écrire le prompt système v1 en s'appuyant sur ce document. La première démo fonctionnelle (booking FR en chat) est réalisable en 2 semaines.